

Prueba Técnica Data Analyst

Cadena de retail multiformato con presencia en 5 países de Centroamérica. Datos sintéticos · 18 meses de historia · 6 archivos CSV.

🕒 7-8 horas

📁 6 bloques

📊 6 datasets

🚩 INSTRUCCIONES GENERALES



Entrega todo en un repositorio **GitHub o GitLab** con un **README.md** claro que explique cómo correr tu código.



Puedes usar **SQL, Python, Power BI, Tableau, Looker Studio** o cualquier combinación de herramientas.



El dataset cubre **enero 2024 – junio 2025** con datos de 40 tiendas en 5 países y 4 formatos.



Comenta tu código. Si no terminas algo, documenta tu razonamiento — el pensamiento vale tanto como el resultado.



El **Bloque 5** (presentación ejecutiva) se entrega en **inglés nivel básico a intermedio** — se valora claridad sobre perfección gramatical. **No se requiere exposición en vivo.**



Uso de IA: Es válido y bienvenido usar herramientas como ChatGPT, Copilot u otras como asistente. Documenta en tu **README.md** : qué prompts usaste, qué generó la IA y qué modificaste tú, y qué validaste manualmente. Evaluamos el criterio con que usas la IA, no solo el output final.

📄 transactions.csv		
CAMPO	TIPO	DESCRIPCIÓN
transaction_id	STRING	ID único de la transacción
customer_id	STRING	ID del cliente — nulo si no usa tarjeta de lealtad
transaction_date	DATE	Fecha de la transacción
store_id	STRING	FK → stores
total_amount	FLOAT	Monto total reportado de la transacción
payment_method	STRING	CASH, CARD, DIGITAL
loyalty_card	BOOLEAN	Si el cliente usó tarjeta de lealtad
status	STRING	COMPLETED, RETURNED

📄 transaction_items.csv		
CAMPO	TIPO	DESCRIPCIÓN
transaction_item_id	STRING	ID único del ítem en la transacción
transaction_id	STRING	FK → transactions
item_id	STRING	FK → products
quantity	INT	Unidades compradas
unit_price	FLOAT	Precio al momento de la venta
was_on_promo	BOOLEAN	Si el ítem estaba en promoción

📄 stores.csv		
CAMPO	TIPO	DESCRIPCIÓN
store_id	STRING	ID único de la tienda
store_name	STRING	Nombre de la tienda
country	STRING	CR, GT, HN, SV, NI
city	STRING	Ciudad
format	STRING	HIPERMERCADO, SUPERMERCADO, DESCUENTO, EXPRESS
size_sqm	INT	Tamaño en metros cuadrados
opening_date	DATE	Fecha de apertura de la tienda
region	STRING	Capital, Norte, Sur, Oriente, Occidente

📄 products.csv		
CAMPO	TIPO	DESCRIPCIÓN
item_id	STRING	ID único del producto
item_name	STRING	Nombre del producto
brand	STRING	Marca
vendor_id	STRING	FK → vendors
category	STRING	Alimentos, Bebidas, Hogar, Electrónica, Ropa, Cuidado Personal, Limpieza, Juguetes

CAMPO	TIPO	DESCRIPCIÓN
department	STRING	Departamento
cost	FLOAT	Costo unitario del producto

vendors.csv		
CAMPO	TIPO	DESCRIPCIÓN
vendor_id	STRING	ID único del proveedor
vendor_name	STRING	Nombre del proveedor
country	STRING	País de origen
tier	STRING	A, B, C
is_shared_catalog	BOOLEAN	Si el producto está disponible en todos los formatos

store_promotions.csv		
CAMPO	TIPO	DESCRIPCIÓN
store_id	STRING	FK → stores
promo_name	STRING	Nombre del experimento
variant	STRING	CONTROL o TREATMENT
start_date	DATE	Inicio de la promoción
end_date	DATE	Fin de la promoción
promo_type	STRING	PRECIO, EXHIBICION, COMBO

Auditoría de Calidad de Datos

ENTREGABLE: bloque0_auditoria.md (o sección en el notebook)

Antes de cualquier análisis, audita el dataset completo. Para cada hallazgo documenta qué encontraste y qué decisión tomarás en los bloques siguientes.

DIMENSIÓN	PREGUNTA A RESPONDER
Compleitud	¿Qué porcentaje de transacciones no tiene <code>customer_id</code> ? ¿Es consistente con <code>loyalty_card = FALSE</code> ?
Consistencia	¿El <code>total_amount</code> en <code>transactions</code> coincide con la suma de <code>unit_price × quantity</code> en <code>transaction_items</code> ?
Unicidad	¿Existen <code>transaction_id</code> duplicados?
Validez	¿Hay <code>total_amount</code> negativos o cero? ¿Hay <code>unit_price = 0</code> con <code>was_on_promo = FALSE</code> ?
Integridad referencial	¿Hay <code>store_id</code> en <code>transactions</code> que no existan en <code>stores</code> ? ¿ <code>vendor_id</code> en <code>products</code> que no existan en <code>vendors</code> ?
Frescura	¿Hay tiendas con gaps de días consecutivos sin transacciones? ¿Son esperables o sospechosos?
Integridad temporal	¿Existe alguna tienda con transacciones anteriores a su <code>opening_date</code> ?
A/B Test	¿Hay tiendas asignadas simultáneamente a <code>CONTROL</code> y <code>TREATMENT</code> en <code>store_promotions</code> ?

💡 Documenta cada hallazgo con evidencia (conteo de filas afectadas) y la decisión que tomarás: ignorar, corregir, excluir o marcar como alerta.

SQL Avanzado

ENTREGABLE: `bloque1_queries.sql` con todas las queries comentadas

Puedes usar SQL estándar o BigQuery SQL. Prioriza legibilidad, eficiencia y buenas prácticas.

Query 1 Ventas comparables (Comp Sales)

Métrica estándar de retail

Calcula el crecimiento YoY **solo para tiendas que estuvieron operando en ambos períodos** (excluye tiendas abiertas hace menos de 13 meses). Por país y formato muestra:

- GMV año actual vs. año anterior
- Comp Sales Growth %
- Ranking de tiendas por crecimiento dentro de su formato

Query 2 Productividad por metro cuadrado

KPI operativo

Para cada tienda calcula GMV total del último trimestre, GMV/m², número de transacciones/m², ticket promedio y ranking dentro de su formato.

Identifica las tiendas **por debajo del percentil 25** de GMV/m² dentro de su formato — márcalas como **BAJO_RENDIMIENTO**.

Query 3 Análisis de cohortes de clientes con tarjeta de lealtad

Retención

Para clientes identificados (`loyalty_card = TRUE`), define la cohorte por **mes de primera transacción**. Calcula:

- Tamaño de cada cohorte (clientes únicos)
- Tasa de retención mensual: % que volvió en los meses 1, 2, 3 y 6
- Ticket promedio de la cohorte en cada período
- Si el ticket crece o decrece con el tiempo para los clientes retenidos

Resultado esperado: **tabla pivotada** con cohortes en filas y meses en columnas.

Query 4 GMROI por proveedor y categoría

Gross Margin Return on Investment

Para cada combinación de vendor y categoría calcula GMV, costo total, margen bruto, **GMROI = Margen Bruto / Costo Total**, SKUs activos y velocidad de venta (unidades/día).

Marca los vendors con **GMROI < 1** — están generando menos margen que lo que cuestan.

Query 5 Detección de posibles quiebres de stock

Análisis operativo

Un ítem tiene un posible quiebre si pasó **3 o más días consecutivos sin registrar ninguna venta** en una tienda donde históricamente sí lo vendía.

Devuelve: tienda, ítem, categoría, fechas del gap, duración en días, ventas promedio diarias antes del gap y GMV estimado perdido.

Ordena por GMV perdido estimado descendente.

Query 6 Impacto de promociones en ticket y volumen

Basket analysis

Usando `was_on_promo` en `transaction_items`, compara por categoría el ticket promedio y las unidades promedio entre transacciones con y sin ítems en promo.

¿Las promociones generan compras adicionales (basket uplift) o solo descuento en lo que ya se iba a comprar?

Modelado de Datos + Diseño de Pipeline

ENTREGABLE: `bloque2_modelo.pdf` + `bloque2_decisiones.md`

A

Modelo Dimensional

Diseña un **Star Schema en BigQuery** que soporte: Comp Sales por tienda/formato/país/periodo, GMROI por vendor/categoría/región, retención de clientes por cohorte, productividad de tienda y análisis de promociones.

Incluye:

- Diagrama del modelo (draw.io, dbdiagram.io, Lucidchart o a mano)
- Tablas de hechos y dimensiones con sus campos clave
- Justificación de **al menos 3 decisiones de diseño** — ej. cómo modelar que el 60% de transacciones no tiene `customer_id`

B

Diseño del Pipeline ETL/ELT

Sin escribir código, responde en texto o diagrama de flujo:

- ¿Cómo manejarías que las tiendas reportan ventas con hasta 2 horas de retraso?
- ¿Cómo detectarías automáticamente que una tienda dejó de enviar datos?
- ¿Cómo harías cargas incrementales sin duplicar transacciones?
- ¿Con qué frecuencia correría el pipeline si el dashboard necesita refresh diario?

C

Gobernanza

- ¿Cómo protegerías `customer_id` para cumplir con políticas de privacidad?
- ¿Quién debería ser el data owner de la tabla de transacciones?
- Si dos reportes muestran GMV diferente para la misma tienda y el mismo día — ¿cuál sería tu proceso para resolverlo?

Análisis Exploratorio + Experimentación

ENTREGABLE: bloque3_analisis.ipynb / .html / .pdf + visualizaciones exportadas (Python, R, SQL u otra herramienta – opcional)

PARTE A — ANÁLISIS EXPLORATORIO

Pregunta 1 — Estacionalidad por formato

¿Cómo evoluciona el GMV semanal por formato de tienda? ¿Qué formato es más sensible a la estacionalidad? Identifica los 3 picos y las 3 caídas más significativas del período y propón una hipótesis para cada uno.

Pregunta 2 — Pareto de categorías por formato

¿Qué categorías concentran el 80% del GMV? ¿Las categorías líderes en **HIPERMERCADO** son las mismas que en **DESCUENTO**? ¿Qué dice esto sobre el perfil del comprador de cada formato?

Pregunta 3 — Cohortes de lealtad

Con base en la Query 3 del Bloque 1: ¿las cohortes más recientes retienen mejor o peor que las antiguas? ¿El ticket promedio de los clientes retenidos crece con el tiempo? ¿En qué mes se da la mayor caída y qué hipótesis tienes?

Pregunta 4 — Quiebres de stock y su impacto

Con los gaps detectados en la Query 5: ¿hay categorías o proveedores donde los quiebres son sistemáticos? ¿Cuánto GMV total estimado se perdió? ¿Es un problema de demanda o de abastecimiento?

Pregunta 5 — Hallazgo libre

Identifica por tu cuenta **un hallazgo relevante** que no estaba en las preguntas anteriores. Muéstralo con evidencia y explica el impacto para el negocio.

PARTE B — INTERPRETACIÓN DE A/B TEST

 **Escenario:** El equipo de merchandising probó una nueva estrategia de exhibición en punto de venta. Se seleccionaron tiendas aleatoriamente: unas recibieron la nueva exhibición (**TREATMENT**), otras mantuvieron la exhibición estándar (**CONTROL**). El test corrió **6 semanas** (septiembre–octubre 2024).

- 1 Validación del experimento.** ¿Los grupos son comparables en GMV base, formato y tamaño antes del test? ¿Hay alguna tienda asignada a ambos grupos?
- 2 Resultado en GMV.** ¿El GMV promedio semanal por tienda en TREATMENT es significativamente mayor? Usa un t-test. Reporta: diferencia absoluta, lift relativo, p-value e intervalo de confianza al 95%.
- 3 Resultado en ticket y frecuencia.** ¿El efecto viene de tickets más altos, de más transacciones por tienda, o de ambos?
- 4 Decisión de negocio.** ¿Implementarías la nueva exhibición en todas las tiendas? Argumenta considerando el p-value, el tamaño del efecto y el costo de implementación. ¿Qué harías si el p-value es 0.08?

Diseño de KPIs desde Cero

ENTREGABLE: bloque4_kpi_framework.md

El equipo directivo quiere lanzar un **programa de mejora de productividad de tiendas**. No existe ningún framework de KPIs aún. Tu trabajo es construirlo desde cero.

Para cada KPI define:

KPI	DEFINICIÓN EXACTA	FÓRMULA	FRECUENCIA	FUENTE DE DATOS	TARGET SUGERIDO	¿CÓMO DETECTAS SI EL DATO ESTÁ MAL?
-----	-------------------	---------	------------	-----------------	-----------------	-------------------------------------

Completa esta tabla con mínimo 6 y máximo 10 KPIs

Restricciones:

- Mínimo 6 KPIs, máximo 10
- Cubre al menos 3 dimensiones: **productividad de tienda**, **experiencia del cliente** y **desempeño de proveedor**
- Al menos un **leading indicator** (predictivo, no solo de resultado final)
- Al menos un KPI **compuesto** (calculado a partir de otros KPIs)
- Define el **North Star Metric** del programa y justifica por qué lo elegiste

Dashboard + Presentación Ejecutiva

ENTREGABLE: archivo .pbix / .twbx / link Looker + PDF en inglés

PARTE A — DASHBOARD OPERATIVO

Construye un dashboard que un **gerente regional pueda usar a diario sin soporte técnico**. Si necesitas explicarle cómo usarlo, el diseño falló.

- **Header:** GMV neto, número de transacciones, ticket promedio, GMV/m² — con variación vs. semana anterior
- **Filtros:** país, formato de tienda, región, rango de fechas
- **Ranking visual** de tiendas por desempeño dentro de su formato
- **Comp Sales:** tendencia semanal año actual vs. año anterior por formato
- **Alerta automática:** tiendas con GMV/m² por debajo del percentil 25 marcadas en rojo
- **Retención:** visualización de la tabla de cohortes del Bloque 1 — Query 3
- **Stock:** lista de items con mayor duración de quiebre activo por tienda

PARTE B — EXECUTIVE PRESENTATION in English — basic to intermediate level

💡 **Nota sobre el nivel de inglés:** No necesitas gramática perfecta ni vocabulario avanzado. Enfócate en ser claro y organizado. Oraciones cortas y bullet points son completamente válidos. **No se requiere presentar en vivo** — la presentación se entrega como archivo PDF.

Máximo 5 slides dirigidas al VP de Operaciones:

1

Executive Summary

3 key findings, written simply and clearly

2

Store Performance

Comp Sales results, best and worst formats or markets

3

Opportunities

Underperforming stores, low GMROI vendors, loyalty insights

4

Risks

Stock-out impact, retention drop, data audit findings

5

Recommendations

What to do, who should do it, and by when

Lo que evaluamos:

- Inglés claro y simple — evita oraciones largas y complejas
- Cada recomendación debe incluir al menos un número (% , \$, número de tiendas, días)
- Los hallazgos deben tener sentido sin ver los datos
- Flujo lógico de hallazgos a recomendaciones

📦 ENTREGABLES FINALES

Estructura esperada del repositorio `prueba_tecnica_[tu_nombre]/` :

<code>README.md</code>	Instrucciones para correr el código + documentación de uso de IA si aplica
<code>bloque0_auditoria.md</code>	O sección en el notebook
<code>bloque1_queries.sql</code>	Todas las queries comentadas
<code>bloque2_modelo.pdf</code>	Diagrama del Star Schema
<code>bloque2_decisiones.md</code>	Decisiones de diseño + ETL + gobernanza
<code>bloque3_analisis.*</code>	Análisis exploratorio + A/B test (.ipynb, .html, .pdf, .R — el formato es libre)
<code>bloque3_visualizaciones/</code>	Imágenes exportadas
<code>bloque4_kpi_framework.md</code>	Framework de KPIs
<code>bloque5_dashboard.*</code>	Archivo .pbix / .twbx / link a Looker Studio
<code>bloque5_presentacion_EN.pdf</code>	Presentación en inglés

🏆 CRITERIOS DE EVALUACIÓN

BLOQUE	PESO	QUÉ SE EVALÚA
Bloque 0 — Calidad de datos	10%	Profundidad de auditoría, hallazgos documentados, decisiones justificadas
Bloque 1 — SQL	20%	Correctitud, eficiencia, uso de funciones avanzadas, legibilidad
Bloque 2 — Modelado + ETL	15%	Decisiones de diseño, escalabilidad, gobernanza
Bloque 3 — Análisis + A/B	25%	Rigor estadístico, profundidad de hallazgos, narrativa de datos
Bloque 4 — KPI Design	10%	Cobertura de dimensiones, North Star bien justificado
Bloque 5 — Dashboard + Pres.	15%	Usabilidad del dashboard, claridad de la presentación en inglés
Calidad general	5%	README, estructura del repo, código reproducible, comentarios